



종합 설계

- 딥 러닝을 활용한
선과 시스템 개발 -

학 과: 정보통신공학과

지도교수: 박 장 우 교수님

팀 명: New-Learn

팀 원: 강동우, 이승기, 김운태, 조재경

Contents

1. 시스템 소개

- (1) 전체 시스템 구성
- (2) 개발 배경
- (3) 동작과정

3. 시스템 구현

- (1) 프로그래밍 언어
- (2) 프로그래밍 환경
- (3) 라이브러리
- (4) 딥 러닝 모델
- (5) 구현 결과

2. 핵심 개념

- (1) Machine Learning
- (2) Deep Learning

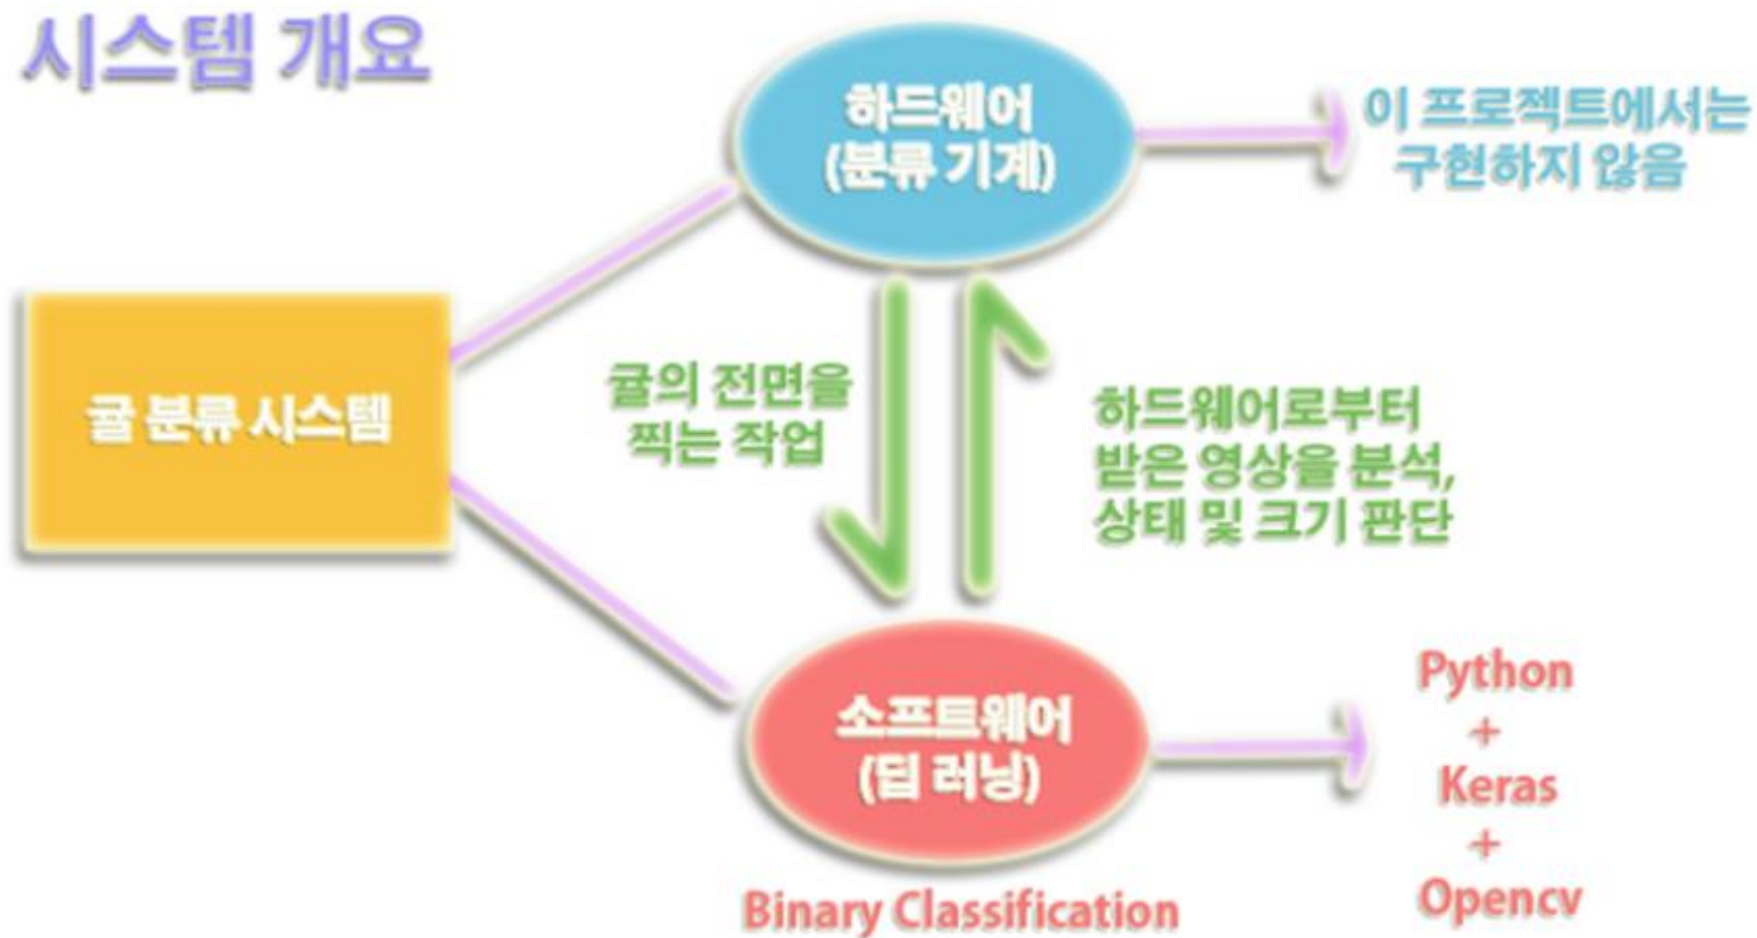
4. 결론



1. 시스템 소개

(1) 전체 시스템 구성

시스템 개요



(2) 개발 배경



국내 과일 분류기1([↑영상](#))

국내 과일 분류기

중량이나 크기로만 등급 결정
→ 포장 시 육안으로 상태 구별

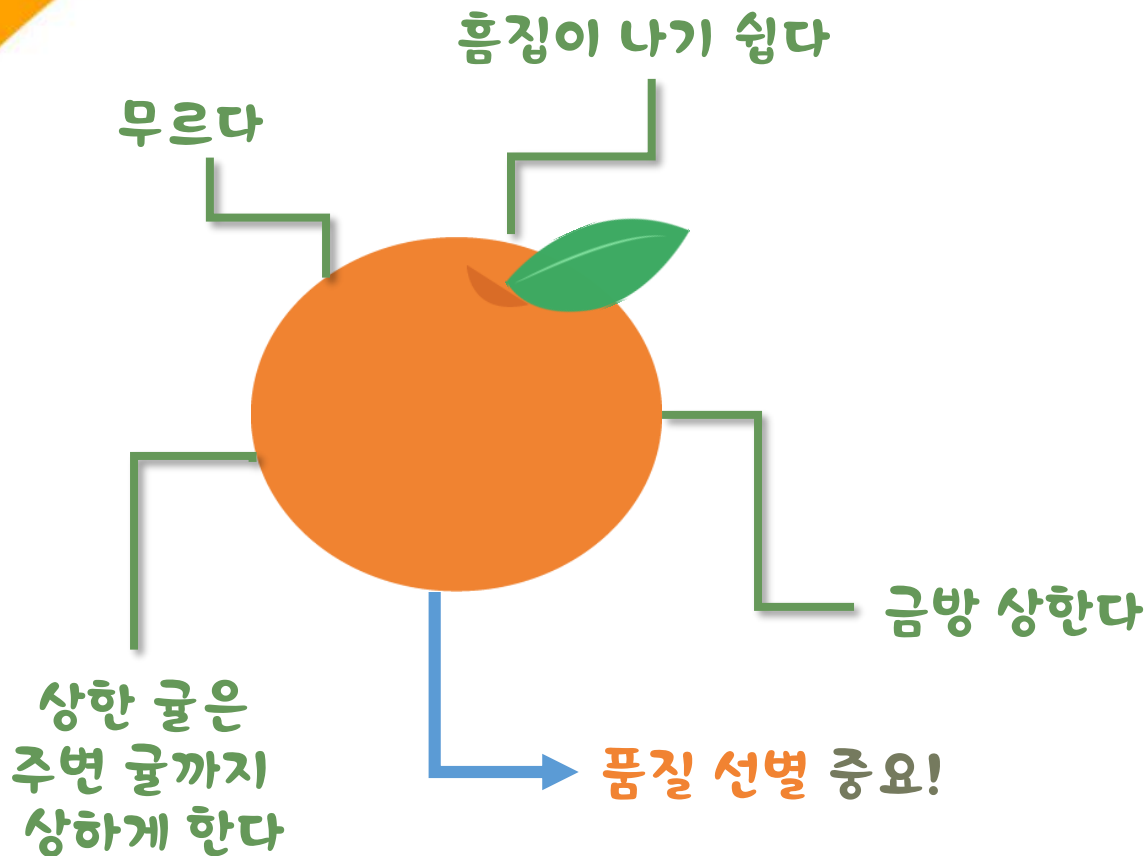


국내 과일 분류기2([↑영상](#))


- 추가적인 인건비 발생
- 투자한 시간에 비해
작업량이 떨어져
비효율적
- 궤의 상태를
다각도로
볼 수 없음



왜 귤을 선택했나?



[출처] 과실생산량(2017, [통계청](#))



다른 과일보다 생산량이 많다!

→ 효율적인 귤 선별기는 수요가 있을 것이다!

🍊 북한에 보낸 200톤 귤 선별 작업



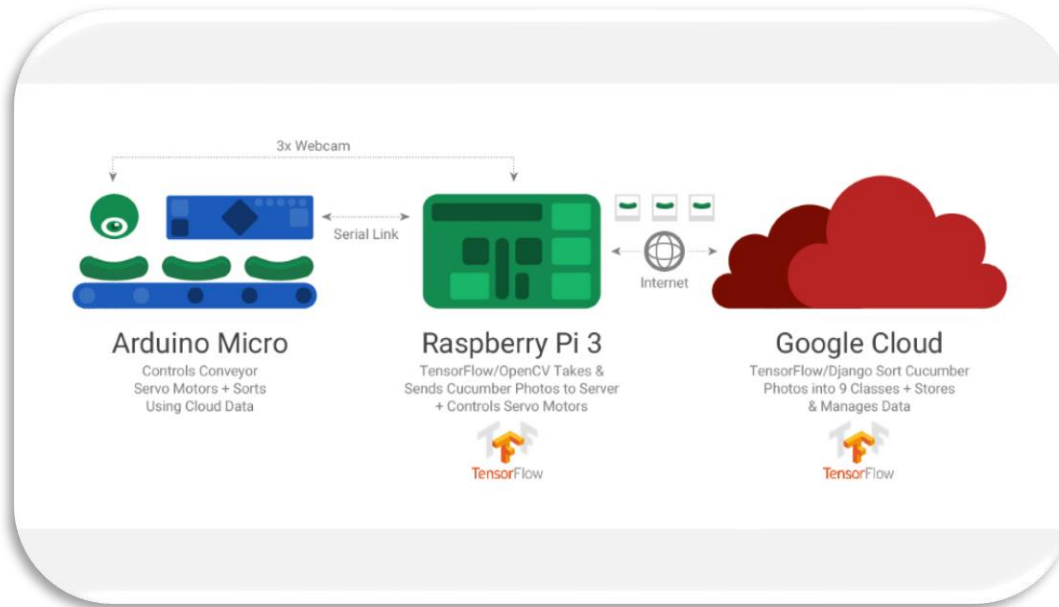
[출처] 채널A 뉴스

컴퓨터로 선별하면
인건비는 줄이고
정확도를 높일 수 있지 않을까?



유사 사례 - 딥 러닝을 적용한 일본의 오이 농가

“크기, 두께, 색상, 질감, 작은 흠집, 구부러짐 여부, 가시가 있는지 여부 등을 살펴야 합니다.
분류 체계를 익히는데 여러 달이 걸리고, 가장 바쁜 시기에 아르바이트를 고용할 수 없습니다.”



=> 딥 러닝을 활용하면 굴 분류 체계를 익히는 시간을 줄일 수 있다!

(3) 시스템 동작 과정

- 가정: 2가지 상태
(Good / Bad)



Good



Bad





●가상의 분류 기계




기계는 만들지 X
이런 기계가 있다고 가정

● 가상 분류기 동작

Good



Bad



4개의 카메라로
굴 4면을 찍음

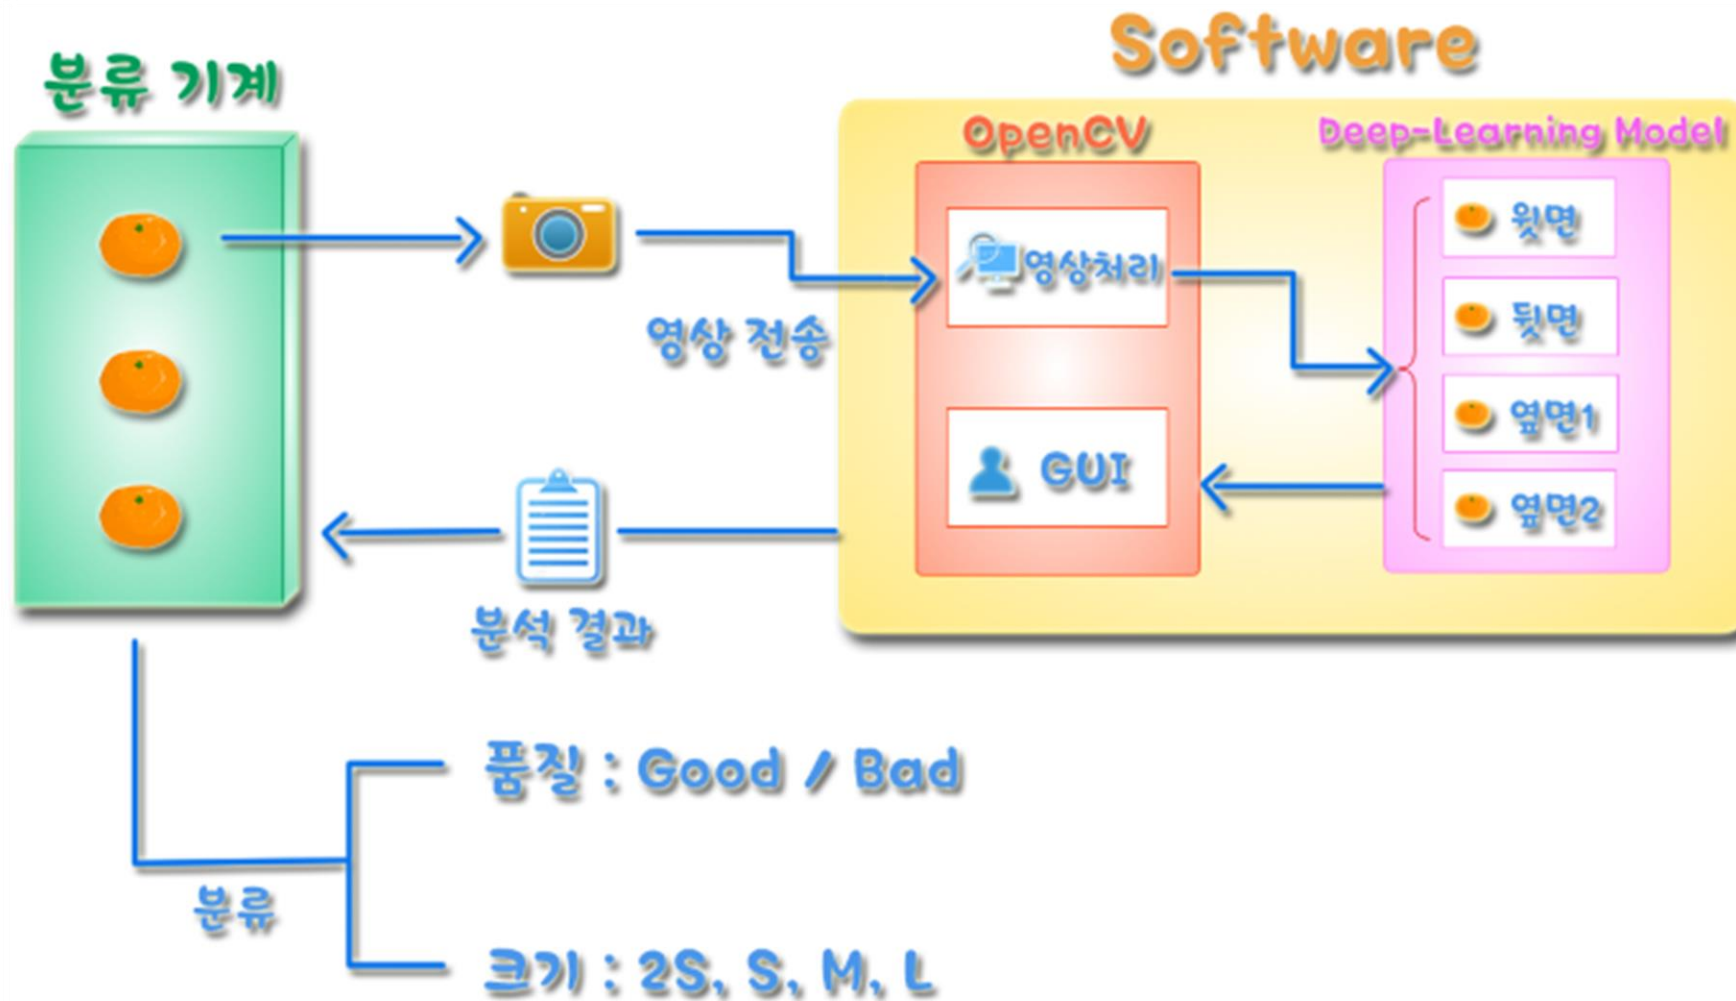


딥 러닝으로
굴 상태 파악



판의 기울기를
조절하여 분류


🍊 동작 과정 요약



2. 핵심 개념

(1) Machine Learning


경험적 데이터를 통해 **컴퓨터 스스로** 새로운 지식과 능력을 개발
학습된 알고리즘으로 **새로운 데이터를 처리**하는 데 중점



AI, ML, DL의 관계

(2) Deep Learning

인공신경망(Neural Network) 알고리즘을 사용하는 머신 러닝의 한 부류
주로 **이미지 인식, 음성 인식** 등의 분야에서 사용



심층 신경망 예시



딥 러닝으로 문제 해결하는 과정

① 어떤 문제를 해결할 것인가 결정

예) 귤의 상태를 분류한다.

② Dataset 모으기

예) 정상 귤 사진과 상한 귤 사진을 6천 장 모았다.

③ Dataset을 train, validation, test set으로 나눈다.



④ 딥 러닝 모델 만들기

예) keras에서 모델 만들기(layer 정의)

```
model = models.Sequential()  
model.add(layers.Dense(256, activation='relu', input_dim=4 * 4 * 512))  
model.add(layers.Dropout(0.5))  
model.add(layers.Dense(1, activation='sigmoid'))
```

⑤ 모델에 Dataset을 훈련 시키고 테스트하기


예) keras에서 모델 훈련 시키기

```
model.compile(optimizer = optimizers.Adam(lr=1e-5),  
              loss = 'categorical_crossentropy',  
              metrics = ['acc'])  
  
history = model.fit(train_features, train_labels,  
                    epochs=30,  
                    batch_size=20,  
                    validation_data=(validation_features, validation_labels))
```

⑥ 훈련이 완료된 모델을 실전에 사용하기




CNN (Convolution Neural Network)




사물을 인식할 때
특정 부분의 모양에 따라
반응하는 뉴런이 다르다


- Filter를 이용하여
이미지의 특징을 추출
- 대표적인 딥 러닝 모델



Single depth slice



max pool with 2x2 filters
and stride 2



특징 추출 후 Sampling 과정을 거친다

예) keras로 간단한 CNN 구현하기

```
model = models.Sequential()  
model.add(layers.Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))  
model.add(layers.MaxPooling2D((2, 2)))  
model.add(layers.Conv2D(64, (3, 3), activation='relu'))  
model.add(layers.MaxPooling2D((2, 2)))  
model.add(layers.Conv2D(64, (3, 3), activation='relu'))
```

3. 시스템 구현

(1) 프로그래밍 언어



- 구조 및 문법이 쉬움

→ 최근 머신 러닝에서
각광 받고 있음

- 머신 러닝에 필요한 라이브러리
쉽게 사용 가능

(2) 프로그래밍 환경



구글이 연구 및 교육 목적으로
딥 러닝을 쉽게 할 수 있도록
제공한 서비스



Python과 수치 해석 라이브러리를
쉽게 사용할 수 있게 해주는 플랫폼

Keras로 처음 구현한 딥 러닝 모델

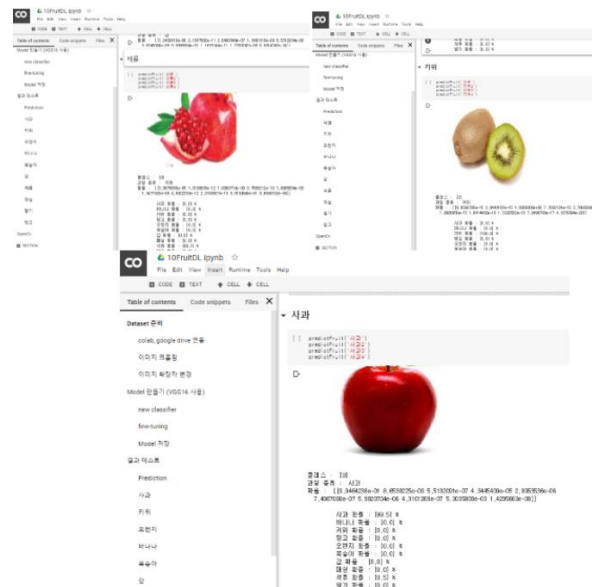
(3) 라이브러리




Keras

Python 기반의
딥 러닝 라이브러리

간결하고 직관적으로
딥 러닝 모델 개발



연습 모델 결과 (10가지 과일 분류)



사과, 바나나, 오렌지, 키위, 감,
망고, 석류, 복숭아, 매실, 딸기

바나나, 사과, 오렌지를
가장 잘 분류함

```
[ ] test_generator = test_datagen.flow_from_directory(  
    test_dir,  
    target_size=(150, 150),  
    batch_size=20,  
    class_mode='categorical')
```

```
test_loss, test_acc = model.evaluate_generator(test_generator, steps=50)  
print('test acc:', test_acc)
```

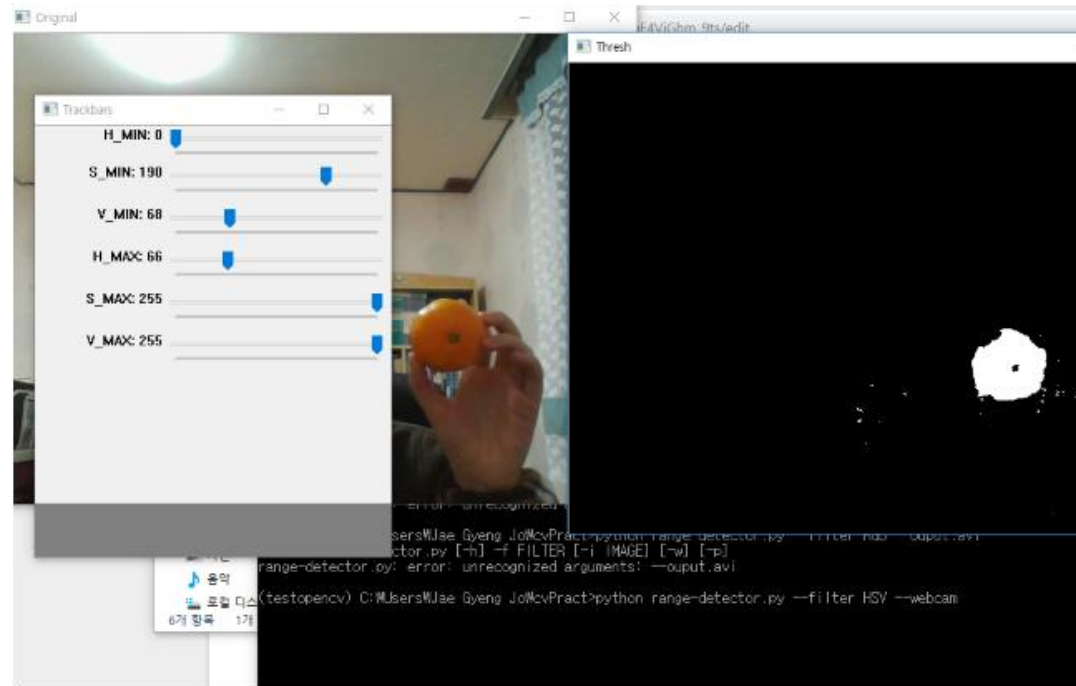
```
Found 7695 images belonging to 10 classes.  
/usr/local/lib/python3.6/dist-packages/PIL/Image.py:872: UserWarning:  
    'to RGB images')  
test acc: 0.8750000011920929
```



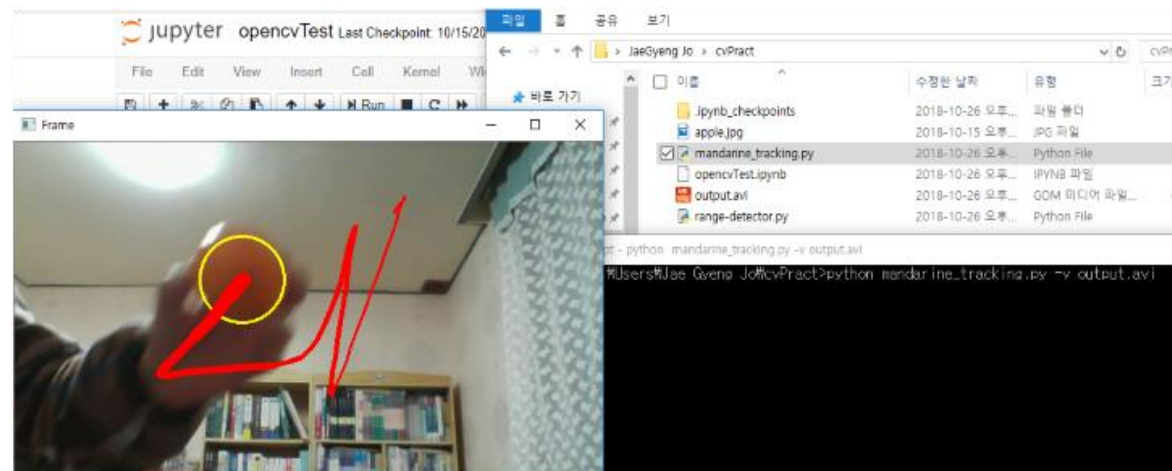
- 실시간 이미지 프로세싱
오픈 소스 라이브러리

- 궤를 tracking하고,
딥 러닝 모델이 분석할
이미지 데이터를 생성하기
위해서 사용

1) 영상 처리

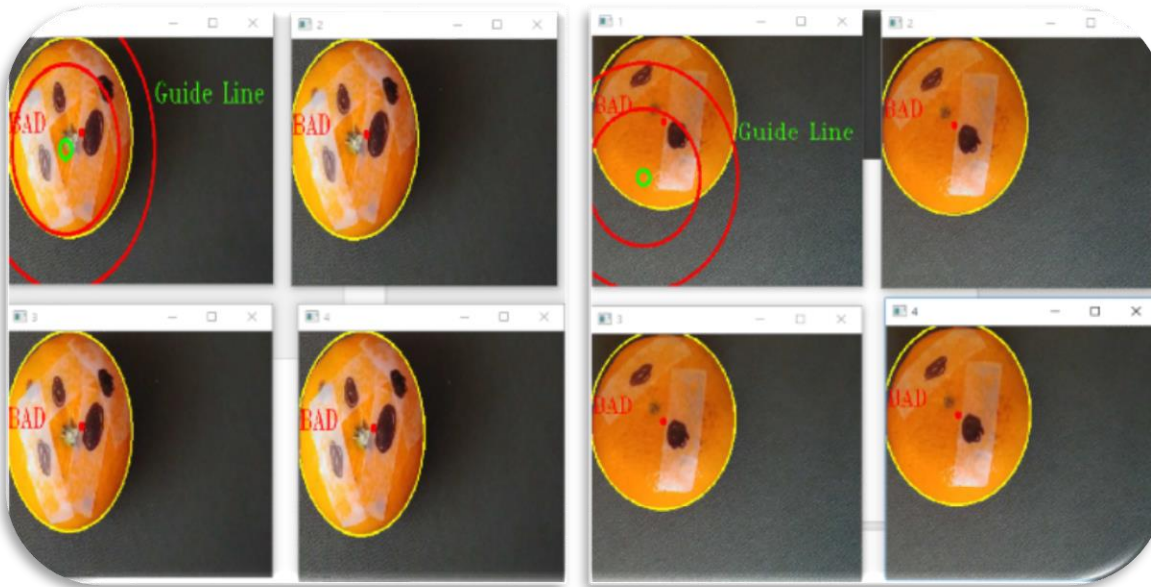


->Masking



-> Tracking

※기계가 없으므로
0.5초마다 4장의 굴 이미지를 자동으로 캡처




→ 딥 러닝 모델이 각각 분석하여
모두 GOOD 판정을 받았을 때만
정상 굴로 분류



굴이 선택된 영역의 반지름으로
굴의 크기를 판단

2) GUI

실행 결과를 보여주기 위해 GUI를 구성



Guide Line:
카메라의 위치에 따라
굴 크기가 다르게
인식되는 것을 방지



안내 및 결과 이미지:
설명, 진행 상황, 결과 보고

(4) 딥 러닝 모델


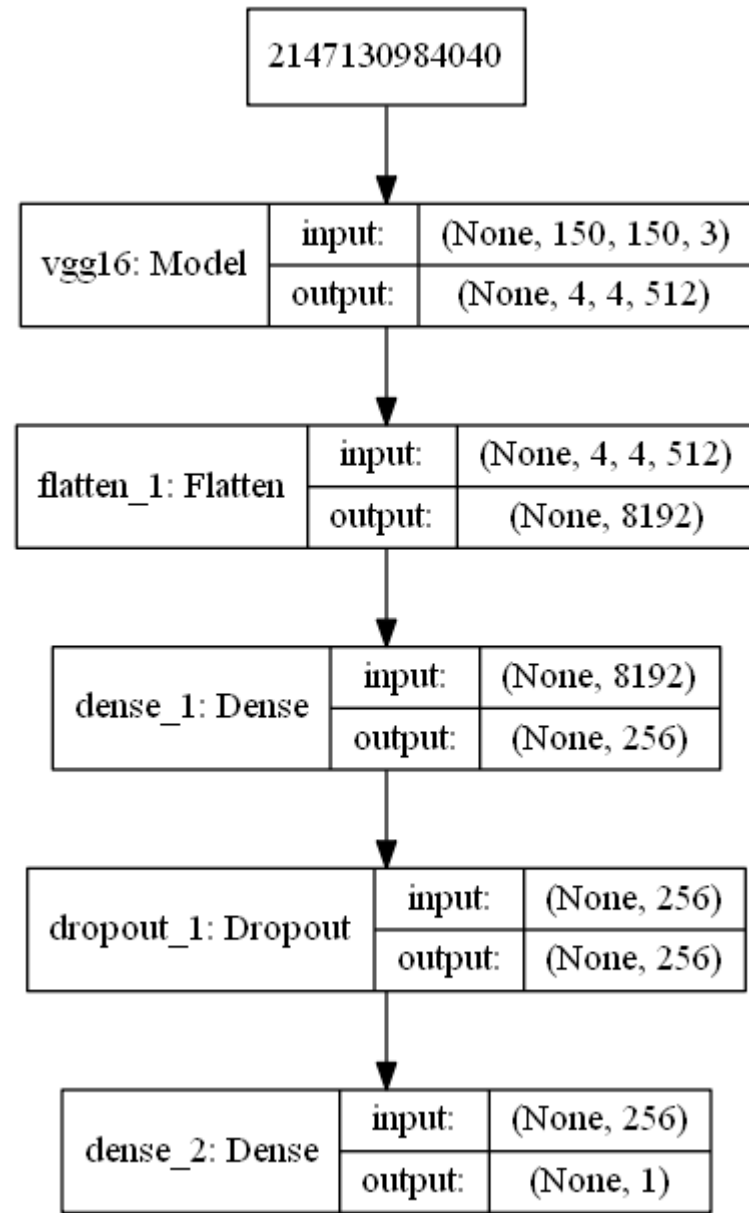
- Binary Classification
-> Good/Bad

- Sequential model 구조

- Pre-trained model 사용
(VGG16-CNN기반)


-> 이미 훈련되어 있어
사물의 특성 잘 찾아냄

-> 적은 데이터셋으로 처음부터
훈련 시키는 것은 힘들기 때문에 사용




🍊 모델 훈련 과정


- 훈련 데이터가 적을 때,
모델이 훈련하면서 데이터를 모두 외워 성능 저하가 발생하는
Overfitting 문제를 줄이도록 훈련



Good Fit/Robust



Overfitted




- VGG16와 다른 pre-trained model들을 이용하여 훈련

-> 가장 성능이 좋은 모델을 선정하여 선과 시스템에 사용함


● Overfitting

- 훈련 데이터를 여러 번 반복 학습을 하고 나면 어느 시점부터 성능이 높아지지 않고 감소
- Overfitting 될수록 새로운 데이터에 취약
- Overfitting 완화 기법

Dropout

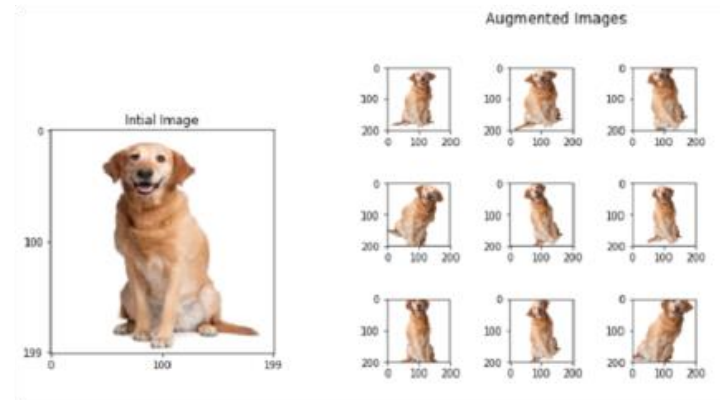


(a) Standard Neural Net

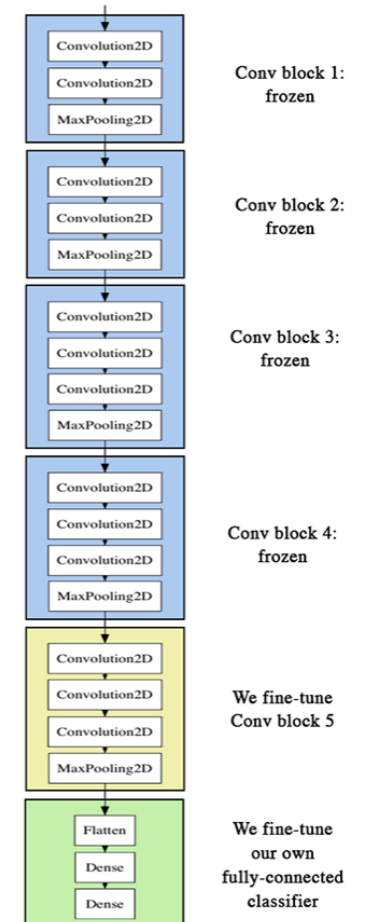


(b) After applying dropout.

Data Augmentation



Fine-Tuning





● Overfitting 기법에 따른 모델 훈련 결과



1) Dropout layer

```
model = models.Sequential()  
model.add(layers.Dense(256, activation='relu', input_dim=4 * 4 * 512))  
model.add(layers.Dropout(0.5))  
model.add(layers.Dense(1, activation='sigmoid'))
```

훈련 데이터
500장



훈련 데이터
2000장



2) Data augmentation

```
train_datagen = ImageDataGenerator(
    rescale=1./255,
    rotation_range=20,
    width_shift_range=0.1,
    height_shift_range=0.1,
    shear_range=0.1,
    zoom_range=0.1,
    horizontal_flip=True,
    fill_mode='nearest')
```

```
model = models.Sequential()
model.add(conv_base)
model.add(layers.Flatten())
model.add(layers.Dense(256, activation='relu'))
model.add(layers.Dense(1, activation='sigmoid'))
```



3) Fine-Tuning



```
conv_base.trainable = True
```

```
set_trainable = False
for layer in conv_base.layers:
    if layer.name == 'block5_conv1':
        set_trainable = True
    if set_trainable:
        layer.trainable = True
    else:
        layer.trainable = False
```



```
test_generator = test_datagen.flow_from_directory(
    test_dir,
    target_size=(150, 150),
    batch_size=20,
    class_mode='binary')
```

```
test_loss, test_acc = model.evaluate_generator(test_generator)
print('test acc:', test_acc)
```

Found 1000 images belonging to 2 classes.
test acc: 0.7930000019073487



4) Data augmentation, Dropout, L2 regularization



```
model.summary()
```

Layer (type)	Output Shape	Param #
vgg16 (Model)	(None, 4, 4, 512)	14714688
flatten_1 (Flatten)	(None, 8192)	0
dense_1 (Dense)	(None, 256)	2097408
dropout_1 (Dropout)	(None, 256)	0
dense_2 (Dense)	(None, 1)	257

Total params: 16,812,353
Trainable params: 16,812,353
Non-trainable params: 0


```
In [12]: test_generator = test_datagen.flow_from_directory(
         test_dir,
         target_size=(150, 150),
         batch_size=20,
         class_mode='binary')

test_loss, test_acc = model.evaluate_generator(test_generator, steps=50)
print('test acc:', test_acc)
```


Found 1000 images belonging to 2 classes.
test acc: 0.8710000026226044

● 다른 pre-trained model 사용 결과

InceptionResNetV2



MobileNet



성능은 VGG16와 비슷하나 모델 로드가 느리고
이미지 처리가 오래 걸리므로 실시간 분석에 적합하지 않음

(5)구현 결과



클래스 : [[0]]
품질 등급 : BAD
확률 : [[12.74729]]



클래스 : [[0]]
품질 등급 : BAD
확률 : [[2.1010294]]



클래스 : [[1]]
품질 등급 : GOOD
확률 : [[99.53425]]

```
Anaconda Prompt

width: 439 pixels
height: 332 pixels
channels: 3
2
Class : [[0]]
Mandarine Grade : BAD
Probability : [[0.12374441]]

width: 390 pixels
height: 325 pixels
channels: 3
3
Class : [[1]]
Mandarine Grade : GOOD
Probability : [[0.5942301]]

width: 402 pixels
height: 362 pixels
channels: 3
4
Class : [[1]]
Mandarine Grade : GOOD
Probability : [[0.89407283]]

(cvTest) C:\Users\Wehoau\Dropbox\mandar_ver3\code>python main.py
```

oCam (100, 19, 1611, 986)

Menu Screen Recording Game Recording

Stop Pause Capture 00:00:00 0bytes / 829.

4. 결론


- 6천장 정도의 적은 데이터셋 사용

- > 80% 이상의 정확도

- > 데이터를 더 모을수록 정확도가 더 높아질 것

- => 정확도를 개선하면 실제 농가에서도 사용 가능할 것임

※ 정확도를 높이려면 다양한 변수를 고려하여 데이터를 모아야 할 것임



- 재사용성이 높은 모델

- > 훈련 데이터만 다른 과일로 바꿔주면 됨

- 컴퓨터만 있으면 굴 분류 가능

- > Raspberry Pi 같은 값싼 하드웨어로 만든 기계와 결합 가능

- => 적은 투자 비용으로 인건비를 줄일 수 있음

- 한 번에 굴의 4면을 분석하므로 사람보다 정확하게 분류 가능



